

## Prediksi Penjualan Mi Menggunakan Metode *Extreme Learning Machine* (ELM) di Kober Mie Setan Cabang Soekarno Hatta

Ayustina Giusti<sup>1</sup>, Agus Wahyu Widodo<sup>2</sup>, Sigit Adinugroho<sup>3</sup>

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya  
Email: <sup>1</sup>giusti.link@gmail.com, <sup>2</sup>a\_wahyu\_w@ub.ac.id, <sup>3</sup>sigit.adinu@ub.ac.id

### Abstrak

Kober Mie Setan cabang Soekarno Hatta merupakan sebuah perusahaan yang bergerak pada bidang makanan. Jumlah permintaan konsumen restoran Kober Mie Setan cabang Soekarno Hatta yang tak menentu setiap waktu berpengaruh terhadap sisa bahan baku yang ada karena bahan baku yang terlalu lama disimpan tidak baik untuk dikonsumsi. Ketika permintaan rendah dan bahan baku yang disediakan tinggi, maka sisa bahan baku dari penjualan hari itu akan dibuang. Agar bahan baku tidak terbuang sia-sia, maka prediksi penjualan diperlukan oleh Kober Mie Setan cabang Soekarno Hatta. Dengan prediksi penjualan tersebut restoran dapat memprioritaskan pembelanjaan bahan baku menu tertentu yang memiliki keminatan tinggi sehingga sisa bahan baku dapat berkurang. Penelitian ini diterapkan metode dari Jaringan Syaraf Tiruan (JST) yaitu *Extreme Learning Machine* (ELM) untuk memprediksi penjualan mi di restoran Kober Mie Setan cabang Soekarno Hatta. Proses prediksi penjualan mi di Kober Mie Setan yaitu normalisasi data, proses *training*, proses *testing*, denormalisasi data, dan perhitungan nilai error menggunakan *Mean Square Error* (MSE). Metode ELM memiliki kelebihan dalam *learning speed* dan tingkat *error* yang kecil. Berdasarkan pengujian yang dilakukan untuk mengetahui perbedaan penggunaan fitur data dalam penelitian ini menghasilkan tingkat error terkecil yaitu 0.0171 dengan menggunakan fitur data historis dan fitur data sisa penjualan.

**Kata kunci:** prediksi penjualan, *Extreme Learning Machine*, Jaringan Syaraf Tiruan, MSE

### Abstract

Kober Mie Setan Soekarno Hatta branch is a company engaged in the field of food. The number of consumer demand of restaurant Kober Mie Setan Soekarno Hatta branch that is erratic every time affect the remaining raw materials. Raw materials that are stored for too long are not good for consumption. When demand is low and the raw materials provided are high, then the rest of the raw materials from the day's sales will be discarded. In order for raw materials are not wasted, then the sales prediction required by Kober Mie Setan Sukarno Hatta branch. With these sales predictions the restaurant can prioritize the expenditure of certain menu ingredients that have a high interest so that the remaining raw materials can be reduced. This research applies method of artificial neural network (JST) that is *Extreme Learning Machine* (ELM) to predict the sales of noodles in Kober Mie Setan restaurant of Soekarno Hatta branch. The prediction process of noodles sales in Kober Mie Setan is normalization of data, training process, testing process, data denormalization, and error value calculation using *Mean Square Error* (MSE). ELM method has advantages in learning speed and small error rate. Based on the tests conducted to determine the differences in the use of data features in this study resulted in the smallest error rate of 0.0171 using the features of historical data and features of residual sales data.

**Keywords:** sales prediction, *Extreme Learning Machine*, Artificial Neural Network, MSE

### 1. PENDAHULUAN

Kober Mie Setan merupakan salah satu restoran dengan menu utama mi. Permintaan konsumen terhadap menu utama di Kober Mie Setan selalu berubah dan tak menentu setiap

waktu, sehingga memperkirakan jumlah permintaan konsumen di masa yang akan datang adalah sangat penting bagi Kober Mie Setan. Prediksi penjualan yang akurat dapat membantu Kober Mie Setan dalam menentukan pembelanjaan bahan baku yang dibutuhkan agar dapat memenuhi kebutuhan konsumen dengan

cepat dan tepat. Dengan adanya prediksi penjualan, restoran dapat memprioritaskan pembelanjaan bahan baku menu tertentu yang memiliki keminatan tinggi sehingga sisa bahan baku dapat berkurang.

Penelitian sebelumnya dengan judul “Prediction of Lase Cutting Heat Affected Zone by Extreme Learning Machine” oleh Anicic, Jovic, & Nedic (2016). Penelitian ini membahas tentang prediksi pemotongan laser pada *Heat Affected Zone* (HAZ) berdasarkan faktor yang berbeda menggunakan *Extreme Learning Machine* (ELM). Hasil dari prediksi ini dibandingkan dengan algoritma lain yaitu *Genetic Algorithm* (GP) dan *Artificial Neural Network* (ANN). Dari perbandingan nilai error menggunakan RMSE didapatkan bahwa ELM memiliki nilai yang rendah dibandingkan dengan GP dan ANN.

Penelitian lainnya masih dengan topik peramalan yaitu tentang peramalan penjualan untuk produk *fashion* yang ditulis oleh Yu, Choi, & Hui (2011) dengan judul “An Intelligent Fast Sales Forecasting Model For Fashion Product”. Metode yang digunakan dalam penelitian ini adalah ELM sebagai *Forecasting Time of Intelligent Fast Forecasting* (IFSFM) untuk memprediksi penjualan produk *fashion* menggunakan data penjualan dengan beberapa parameter yaitu warna baju, ukuran baju, dan harga baju. Dari penelitian ini percobaan menggunakan data set asli menunjukkan bahwa ELM mampu memberikan tingkat akurasi yang baik dalam batasan waktu yang diberikan.


Pada penelitian ini diterapkan metode dari Jaringan Syaraf Tiruan (JST) yaitu Extreme Learning Machine (ELM) untuk memprediksi penjualan mi di Kober Mie Setan. ELM merupakan JST feedforward dengan satu *hidden layer*. Metode ELM memiliki kelebihan dalam learning speed. ELM merupakan sebuah metode pembelajaran dengan memanfaatkan teori matriks.

Penelitian ini bertujuan memprediksi penjualan restoran Kober Mie Setan dengan metode Extreme Learning Machine (ELM). Dari penelitian sebelumnya prediksi dengan metode ELM menunjukkan tingkat kesalahan yang kecil sehingga sangat cocok untuk memprediksi jumlah permintaan konsumen terhadap menu restoran Kober Mie Setan.

## 2. LANDASAN KEPUSTAKAAN

### 2.1 Jaringan Syaraf Tiruan (JST)

Jaringan syaraf tiruan (JST) merupakan representasi kinerja otak manusia, seperti yang diketahui otak manusia selalu mensimulasikan proses pembelajaran. Dalam JST ini sama seperti otak manusia yang memiliki beberapa *neuron* yang saling memiliki hubungan satu-sama lain. *Neuron-neuron* tersebut mentransfer informasi-informasi yang diterima oleh satu *neuron* ke *neuron* yang lain. Informasi yang dibawa oleh neuron tersebut disimpan pada suatu nilai tertentu yang disebut bobot. Struktur node atau neuron pada jaringan syaraf tiruan ditunjukkan pada Gambar 1 berikut ini.




**Gambar 1** Struktur Jaringan Syaraf Tiruan  
Sumber: (Siwi, Cholissodin and Furqon 2016)

### 2.2 Metode *Extreme Learning Machine* (ELM)

*Extreme Learning Machine* (ELM) diperkenalkan oleh (Huang, Zhu, & Siew, 2004). ELM merupakan metode pengembangan dari jaringan syaraf tiruan *feedforward* sederhana dengan menggunakan satu hidden layer atau biasa dikenal dengan *Single Hidden Layer Feedforward Neural Networks* (SLFNs).

Jaringan *feedforward* menggunakan parameter-parameter yang ditentukan secara manual seperti input weight dan bias. Input weight dan bias ini dibangkitkan secara acak dalam suatu rentang tertentu. Dengan nilai yang diacak tersebut, bisa menghindari hasil prediksi yang tidak stabil. Secara umum struktur ELM ditunjukkan pada Gambar 2.



**Gambar 2** Struktur Metode ELM  
Sumber: (Abadi, Musyafa, Soeprijanto, 2014)

Langkah-langkah perhitungan dengan metode ELM yaitu pertama adalah normalisasi

data kemudian data akan diproses pada langkah proses *training* dan proses *testing*.

### 1. Normalisasi Data

Normalisasi data dilakukan karena range nilai input tidak sama, yaitu bernilai puluhan hingga ribuan. *Input* akan diproses ke nilai *output* yang kecil sehingga data yang digunakan harus disesuaikan agar dapat diproses untuk mendapatkan nilai normalisasi yang kecil. Dalam penelitian ini, data yang digunakan akan disesuaikan dengan cara menormalisasi data. Berikut adalah proses normalisasi data menggunakan metode *Min-Max Normalization* (Jain and Bhandare 2011):

$$d' = \frac{d - \min}{\max - \min} \quad (2.1)$$

Keterangan:

$d'$  = nilai dari hasil normalisasi data

$d$  = nilai asli data

min = nilai minimum pada data set fitur  $X$

max = nilai maksimal pada data set fitur  $X$

### 2. Proses Training

Proses *training* harus dilalui sebelum melakukan proses prediksi. Tujuannya adalah untuk mendapatkan nilai *output weight*. Langkah-langkah proses *training* yaitu sebagai berikut (Huang, Zhu and Siew, 2006):

1. Langkah pertama adalah menginisialisasi *input weight* dan bias. Nilai ini diinisialisasi secara acak dengan range antara -1 hingga 1.
2. Keluaran di *hidden layer* dihitung menggunakan fungsi aktivasi. Langkah pertama adalah menghitung keluaran *hidden layer* ( $H_{init}$ ), setelah nilai  $H_{init}$  didapatkan kemudian dihitung menggunakan fungsi aktivasi sigmoid. Berikut adalah persamaan untuk menghitung keluaran di *hidden layer*:

$$H_{init\ ij} = \left( \sum_{k=1}^n w_{jk} \cdot x_{ik} \right) + b_j \quad (2.2)$$

Keterangan:

$H_{init}$  = Matriks keluaran *hidden layer*.

$i$  =  $[1, 2, \dots, N]$ , dimana  $N$  adalah keseluruhan jumlah data.

$j$  =  $[1, 2, \dots, \tilde{N}]$ , dimana  $\tilde{N}$  adalah keseluruhan jumlah *hidden neuron*.

$n$  = Jumlah *input neuron*.

$w$  = Bobot *input*.

$x$  = *Input* data yang digunakan.

$b$  = Nilai bias.

3. Menghitung *output weight*. Untuk mendapatkan *output weight*, langkah pertama yang harus dilakukan adalah menranspose matriks hasil keluaran *hidden layer* dengan fungsi aktivasi. Setelah ditranspose, matriks transpose tersebut dikalikan dengan matriks hasil keluaran *hidden layer* dengan fungsi aktivasi biasa disebut matriks  $H$ . Langkah selanjutnya adalah menghitung nilai invers dari matriks  $H$  tersebut. Setelah itu menghitung matriks *Moore-Penrose Generalized Invers* dari hasil keluaran *hidden layer* dengan fungsi aktivasi. Berikut adalah persamaan untuk menghitung nilai *output weight*:

$$\beta = H^+ T \quad (2.3)$$

Keterangan:

$\beta$  = Matriks *Output weight*.

$H^+$  = Matriks *Moore-Penrose Generalized Invers* dari matriks  $H$ .

$T$  = Matriks *Target*.

### 3. Proses Testing

Pada proses ini bertujuan untuk mengevaluasi metode ELM dari hasil proses *training* sebelumnya. Proses *testing* dilakukan menggunakan *input weight*, bias dan *output weight* yang didapatkan dari proses *training*. Berikut langkah-langkah proses *testing* adalah sebagai berikut:

1. Langkah pertama adalah menginisialisasi *input weight* dan bias yang telah didapatkan dari proses *training*.
2. Keluaran di *hidden layer* dihitung menggunakan fungsi aktivasi. Pilih salah satu fungsi aktivasi yang digunakan yaitu fungsi aktivasi sigmoid, sin, hardlim.
3. Nilai *output weight* yang telah didapatkan pada proses *training* digunakan untuk menghitung keluaran *output layer* yang merupakan hasil prediksi. Berikut adalah persamaan untuk menghitung nilai *output layer*:

$$y = H\beta \quad (2.4)$$

Keterangan:

$y$  = *Output layer* yang merupakan hasil prediksi.

$\beta$  = nilai *output weight* didapatkan dari proses *training*.

$H$  = Keluaran di *hidden layer* dihitung dengan fungsi aktivasi.

4. Langkah terakhir adalah menghitung nilai *error* semua *output layer*. Nilai *error* ini

menunjukkan nilai kesalahan dari hasil prediksi yang didapatkan.

### 5. Proses Denormalisasi Data

Proses ini berfungsi untuk membangkitkan nilai yang telah dinormalisasi menjadi nilai asli. Berikut adalah persamaan untuk proses denormalisasi data:

$$d = d'(\max - \min) + \min \quad (2.5)$$

Keterangan:

$d'$  = nilai hasil prediksi sebelum didenormalisasi

$d$  = nilai asli setelah didenormalisasi

$\min$  = nilai minimum pada data set fitur  $X$

$\max$  = nilai maksimal pada data set fitur  $X$

### 6. Mean Square Error (MSE)

Mean Square Error (MSE) digunakan untuk mengevaluasi hasil prediksi. Berikut adalah persamaan untuk menghitung nilai *error* pada hasil prediksi (Makridakis and Hibon, 1995):

$$MSE = \frac{\sum_{i=1}^n e_i^2}{n} = \frac{\sum_{i=1}^n (y_i - t_i)^2}{n} \quad (2.6)$$

Keterangan:

$n$  = Jumlah data.

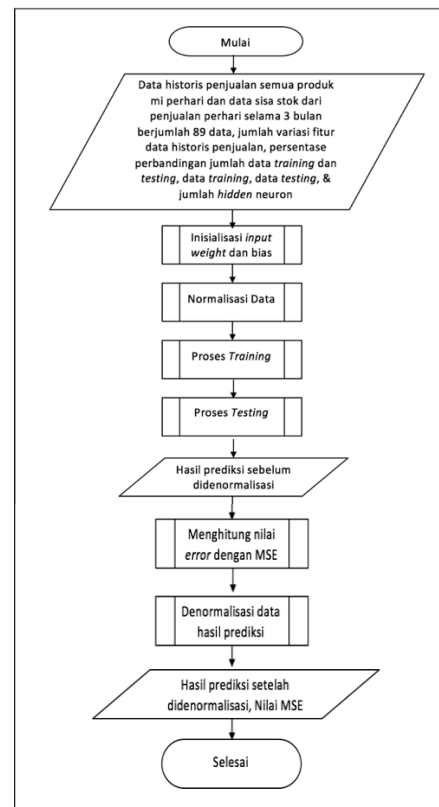
$e$  = Error.

$y_i$  = Nilai output (prediksi).

$t_i$  = Nilai aktual.

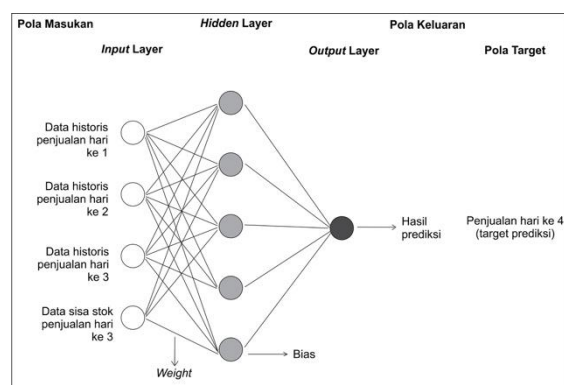
## 3. METODOLOGI

Tujuan dari prediksi penjualan menggunakan metode ELM ini adalah untuk mendapatkan hasil prediksi dengan nilai *error* terkecil. Proses prediksi penjualan menggunakan ELM ini menggunakan data masukan yaitu data historis penjualan semua produk mi dan data sisa penjualan harian. Untuk lebih jelasnya Gambar 3 menunjukkan diagram alir proses prediksi penjualan mi di Kober Mie Setan menggunakan metode ELM.



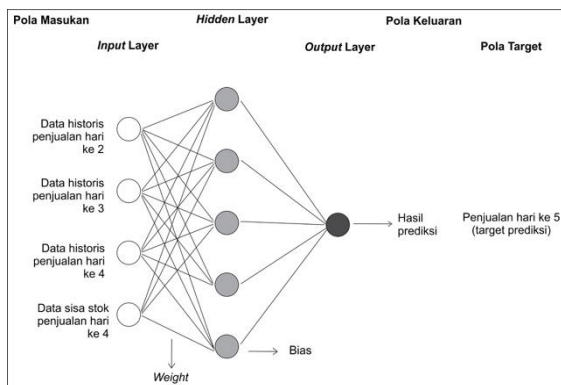
**Gambar 3** Diagram Alir Proses Prediksi Menggunakan ELM

Arsitektur jaringan ELM untuk prediksi penjualan mi di Kober Mie Setan ditunjukkan pada Gambar 4 dan Gambar 5. Gambar 4 menunjukkan arsitektur jaringan ELM untuk proses *training* dan Gambar 5 menunjukkan arsitektur jaringan ELM untuk proses *testing*.



**Gambar 4** Arsitektur ELM untuk Proses *Training*  
Sumber: (Perdana, Soeprijanto and Wibowo 2012)






**Gambar 5** Arsitektur ELM untuk Proses *Testing*  
Sumber: (Perdana, Soeprijanto and Wibowo 2012)

Berdasarkan diagram alir pada Gambar 3, berikut langkah-langkah penyelesaian dengan metode ELM yaitu sistem menerima masukan berupa data historis penjualan, data sisa penjualan harian, jumlah neuron pada *hidden layer* dan fungsi aktivasi sigmoid. Inisialisasi *input weight* dan bias. Proses normalisasi data menggunakan *Min-Max Normalization*. Setelah data dinormalisasi kemudian dilanjutkan ke proses *training* dan proses *testing*. Hasil dari proses *training* adalah hasil prediksi sebelum didenormalisasi. Hasil prediksi sebelum didenormalisasi tersebut kemudian dievaluasi dengan menghitung nilai *error* menggunakan MSE. Keluaran dari sistem merupakan hasil prediksi dari ELM yang telah didenormalisasi.

## 4. PENGUJIAN DAN PEMBAHASAN

### 4.1 Pengujian Jumlah Neuron Pada *Hidden Layer*




**Gambar 6** Hasil Pengujian Jumlah Neuron Pada *Hidden Layer*

Berdasarkan grafik pada Gambar 6, pengujian jumlah neuron pada *hidden layer* menunjukkan bahwa dengan jumlah neuron yang banyak maka akan menghasilkan nilai *error* yang kecil. Hal tersebut dapat dilihat pada saat pengujian menggunakan jumlah neuron 7,

nilai rata-rata MSE yang dihasilkan adalah sebesar 0.0171. Sedangkan, saat menggunakan jumlah neuron pada *hidden layer* 1 didapatkan rata-rata nilai MSE sebesar 0.0585 yang berarti nilai tersebut tinggi. Nilai *error* yang tinggi tersebut dikarenakan *underfitting*. *Underfitting* terjadi ketika proses *training* tidak dapat menangkap pola pembelajaran dengan baik dikarenakan pemroses *input* atau disebut dengan *hidden* neuron berjumlah sedikit, sehingga pola yang ditangkap pada proses *training* terbatas dan menyebabkan *error* yang tinggi ketika proses *testing* dijalankan (Sheela and Deepa 2013). Dapat disimpulkan bahwa dengan jumlah neuron yang banyak maka penghubung antara *input layer* ke *output layer* menjadi banyak sehingga pengenalan pola yang dilakukan sistem semakin baik.


### 4.2 Pengujian Jumlah Data *Training*



**Gambar 7** Grafik Hasil Pengujian Jumlah Data *Training*

Berdasarkan grafik pada Gambar 7 ditunjukkan bahwa nilai MSE terkecil terjadi pada saat jumlah data *training* sebesar 80% terhadap data *testing* sebesar 20% dari dataset dengan rata-rata nilai *error* sebesar 0.0171. Hasil dari pengujian ini dapat disimpulkan bahwa jumlah data *training* berpengaruh terhadap nilai *error* yang dihasilkan untuk jumlah data *testing* sebesar 20%. Pada pengujian ini semakin kecil jumlah data *training* daripada data *testing* maka nilai *error* semakin tinggi dikarenakan adanya *underfitting*. Pada pengujian ini *underfitting* terjadi karena proses *training* tidak mampu melakukan pengenalan pola dengan baik karena jumlah data *training* lebih sedikit dibandingkan jumlah data *testing*. Hal ini disebabkan karena metode ELM merupakan metode pelatihan, sehingga semakin banyak data *training* yang digunakan maka semakin baik prediksi yang dihasilkan ditunjukkan dengan nilai *error* yang kecil.


### 4.3 Pengujian Jumlah Fitur Data Historis Penjualan



**Gambar 8** Grafik Hasil Pengujian Jumlah Fitur Data Historis Penjualan

Berdasarkan grafik pada Gambar 8, nilai MSE paling kecil didapatkan pada jumlah fitur sebanyak 7 sebesar 0.0171. Nilai MSE tinggi pada saat pengujian dengan jumlah fitur 42 dikarenakan jumlah keseluruhan data dalam pengujian ini hanya 89 data sehingga pembagian yang digunakan menjadi lebih sedikit karena data awal digunakan untuk membentuk pola pembelajaran. Semakin banyak jumlah variasi fitur data belum tentu menghasilkan prediksi yang baik, karena proses prediksi menggunakan ELM juga bergantung dengan objek dan fitur yang digunakan.

### 4.4 Pengujian Fitur Data Yang Digunakan



**Gambar 9** Grafik Hasil Pengujian Fitur Data Yang Digunakan

Berdasarkan Tabel 9, rata-rata nilai MSE terkecil yang didapatkan adalah dengan menggunakan fitur data sisa penjualan dengan rata-rata nilai MSE sebesar 0.0171. Dari hasil tersebut dapat disimpulkan bahwa dengan menggunakan fitur data sisa penjualan, prediksi yang dihasilkan akan lebih baik. Gambar 4.4 menunjukkan bahwa grafik hasil pengujian menggunakan fitur data historis penjualan

dengan data sisa penjualan lebih rendah daripada pengujian tanpa menggunakan fitur data sisa penjualan. Semakin banyak pola pembelajaran, prediksi yang dihasilkan akan semakin baik.

## 5. PENUTUP

Berdasarkan hasil pengujian dan pembahasan dari prediksi penjualan mi Kober Mie Setan menggunakan metode *Extreme Learning Machine* (ELM) maka diperoleh kesimpulan sebagai berikut:

- Berikut proses implementasi metode *Extreme Learning Machine* untuk prediksi penjualan mi pada Kober Mie Setan:
  - Proses normalisasi data
  - Proses *training*
  - Proses *testing*
  - Proses perhitungan nilai *Mean Square Error* (MSE)
  - Proses denormalisasi
- Tingkat kesalahan peramalan (*forecast error*) berdasarkan hasil pengujian dan pembahasan yang diukur dengan perhitungan MSE (*Mean Square Error*) pada hasil prediksi penjualan mi pada Kober Mie Setan adalah:
  - Berdasarkan pengujian dan pembahasan yang telah dilakukan jumlah neuron berpengaruh terhadap hasil perhitungan. Hal tersebut terbukti dengan jumlah neuron yang banyak menghasilkan nilai *error* yang kecil sebesar 0.0176 dengan jumlah neuron sebanyak 7.
  - Jumlah data *training* berpengaruh terhadap hasil keluaran prediksi yang dihasilkan untuk jumlah data *testing* sebesar 20%. Berdasarkan pengujian dan pembahasan yang telah dilakukan, jumlah data *training* sebesar 80% menghasilkan nilai rata-rata error terkecil yaitu 0.0171.
  - Berdasarkan pengujian dan pembahasan yang telah dilakukan nilai MSE paling kecil didapatkan pada jumlah fitur sebanyak 7 sebesar 0.0171.
  - Rata-rata nilai MSE terkecil yang didapatkan adalah dengan menggunakan fitur data sisa penjualan dengan rata-rata nilai MSE sebesar 0.0171. Dari hasil tersebut dapat disimpulkan bahwa dengan menggunakan fitur data sisa penjualan, prediksi yang dihasilkan akan lebih baik.

## DAFTAR PUSTAKA

Anicic, O., Jović, S., Skrijelj, H. and Nedić, B., 2017. Prediction of laser cutting heat

- affected zone by extreme learning machine. *Optics and Lasers in Engineering*, 88, pp.1-4.
- Yu, Y., Choi, T.M. and Hui, C.L., 2011. An intelligent fast sales forecasting model for fashion products. *Expert Systems with Applications*, 38(6), pp.7373-7379.
- Perdana, J.A., Soeprijanto, A. and Wibowo, R.S., 2012. Peramalan Beban Listrik Jangka Pendek Menggunakan Optimally Pruned Extreme Learning Machine (OPELM) pada Sistem Kelistrikan Jawa Timur. *Jurnal Teknik ITS*, 1(1), pp.B176-B181.
- Singh, R. and Balasundaram, S., 2007. Application of extreme learning machine method for time series analysis. *International Journal of Intelligent Technology*, 2(4), pp.256-262.
- Huang, G.B., Zhu, Q.Y. and Siew, C.K., 2006. Extreme learning machine: theory and applications. *Neurocomputing*, 70(1), pp.489-501.
- Huang, G.B., Zhu, Q.Y. and Siew, C.K., 2004, July. Extreme learning machine: a new learning scheme of feedforward neural networks. In *Neural Networks, 2004. Proceedings. 2004 IEEE International Joint Conference on* (Vol. 2, pp. 985-990). IEEE.
- Sheela, K.G. and Deepa, S.N., 2013. Review on methods to fix number of hidden neurons in neural networks. *Mathematical Problems in Engineering*, 2013.
- Jain, Y.K. and Bhandare, S.K., 2011. Min max normalization based data perturbation method for privacy protection. *International Journal of Computer & Communication Technology*, 2(8), pp.45-50.
- Abadi, I. and Soeprijanto, A., 2014, November. Extreme learning machine approach to estimate hourly solar radiation on horizontal surface (PV) in Surabaya-East java. In *Information Technology, Computer and Electrical Engineering (ICITACEE), 2014 1st International Conference on* (pp. 372-376). IEEE.
- Siwi, Iga Permata, Imam Cholissodin, and M. Tanzil Furqon, 2016. *Peramalan Produksi Gula Pasir Menggunakan Extreme Learning Machine (Elm) Pada Pg Candi Baru Sidoarjo*. DORO: Repositori Jurnal Mahasiswa PTIIK ( Vol. 8. 12 vols). DORO.
- Makridakis, Spyros, and M. Hibon, 1995. *Evaluating Accuracy (Or Error) Measures. Volume 9518 of Working papers / INSEAD*.